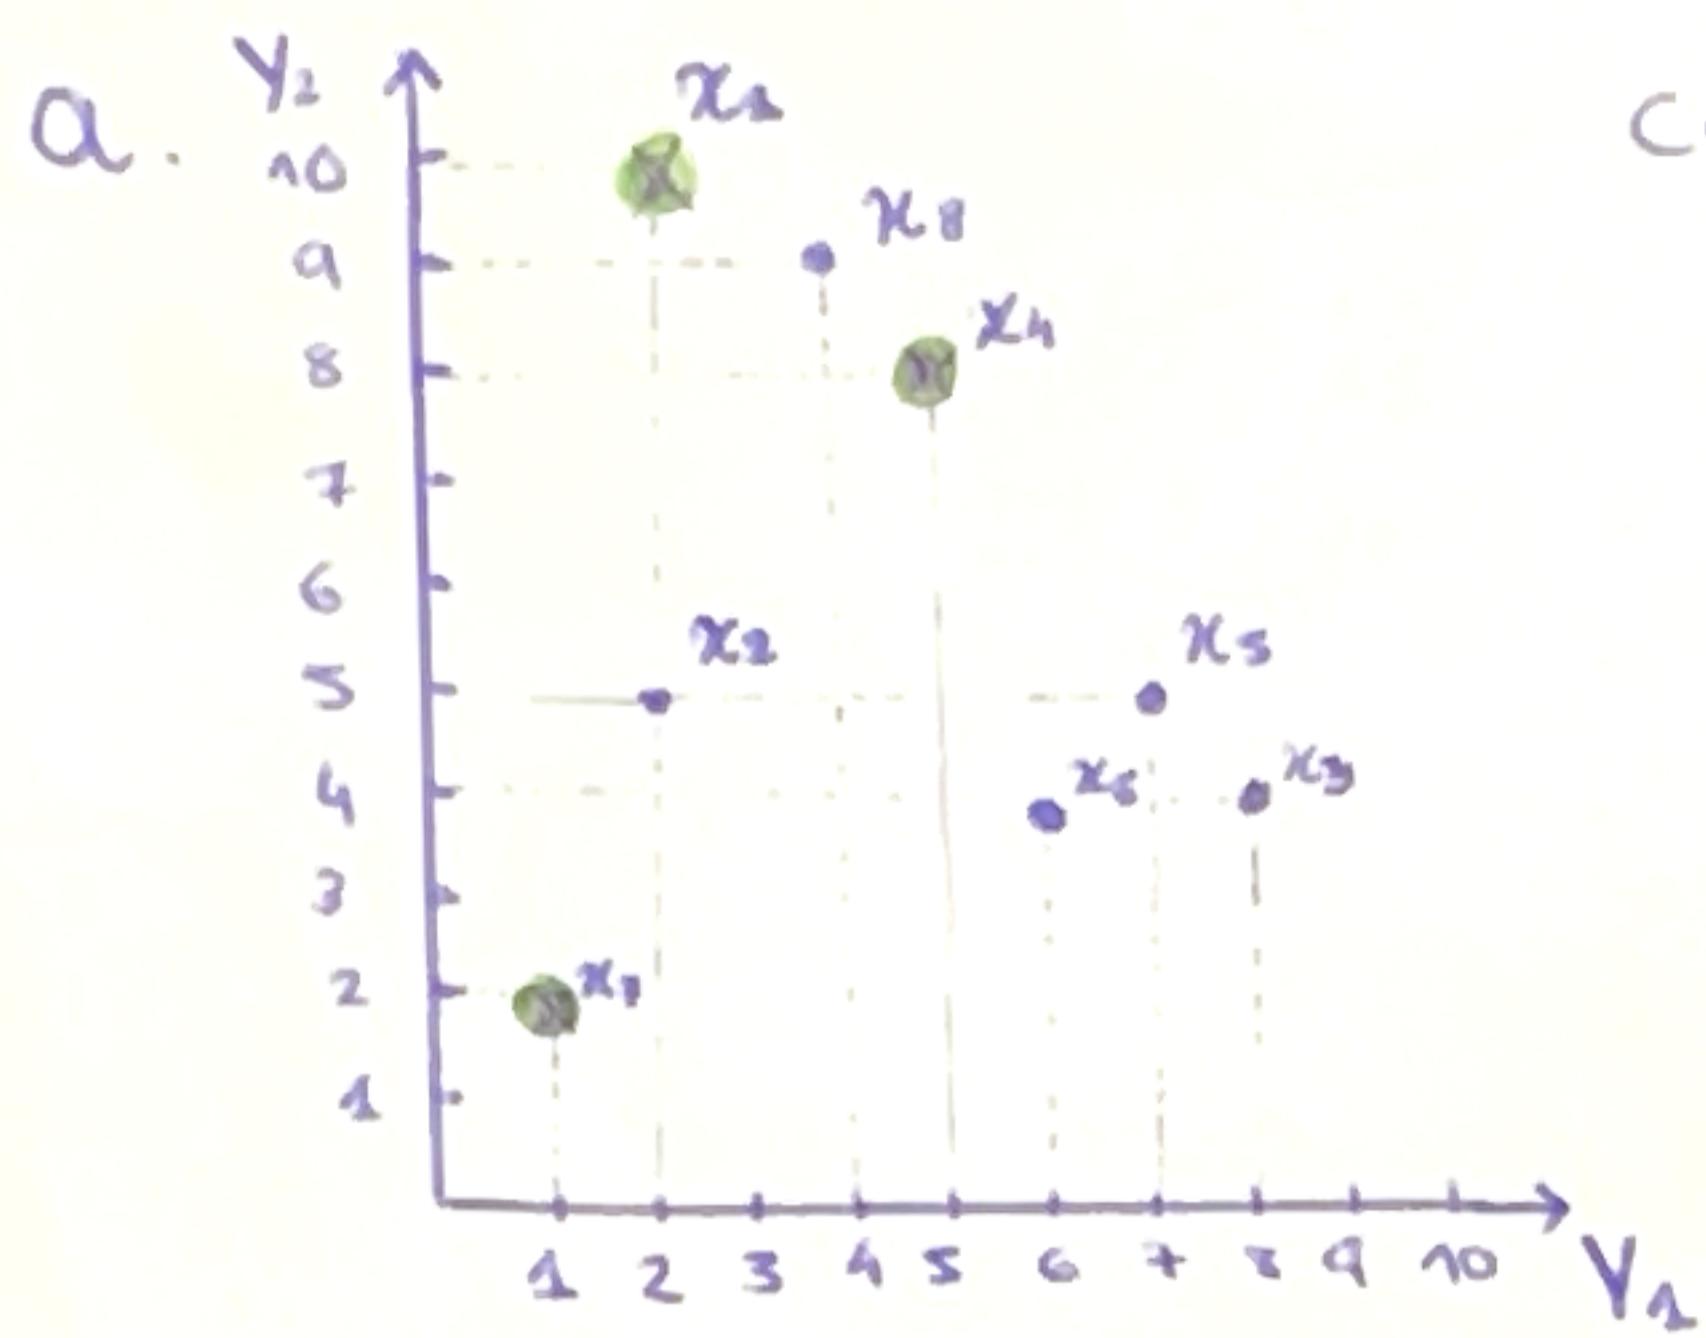


Pen and Paper

Part A - Clustering



Centróides:
 $x_1(2, 10)$
 $x_4(5, 8)$
 $x_7(1, 2)$

b. $K = 3$; 3 centroides \Rightarrow 3 clusters

1) Assign points to clusters

$x_1 \rightarrow C_1$

$x_2(2, 5)$:

$$d(x_1, x_2)^2 = (2-2)^2 + (10-5)^2 = 25 \quad d(x_4, x_2)^2 = (2-5)^2 + (5-8)^2 = 18$$

$$d(x_7, x_2)^2 = (1-2)^2 + (2-5)^2 = 10 \quad \text{Logo } x_2 \rightarrow C_3$$

$x_3(8, 4)$:

$$d(x_1, x_3)^2 = (2-8)^2 + (10-4)^2 = 72 \quad d(x_4, x_3)^2 = (5-8)^2 + (8-4)^2 = 25$$

$$d(x_7, x_3)^2 = (1-8)^2 + (2-4)^2 = 53 \quad \text{Logo } x_3 \rightarrow C_2$$

$x_4 \rightarrow C_2$

$x_5(7, 5)$:

$$d(x_1, x_5)^2 = (2-7)^2 + (10-5)^2 = 50 \quad d(x_4, x_5)^2 = (5-7)^2 + (8-5)^2 = 13$$

$$d(x_7, x_5)^2 = (1-7)^2 + (2-5)^2 = 45 \quad \text{Logo } x_5 \rightarrow C_2$$

$x_6(6, 4)$:

$$d(x_1, x_6)^2 = (2-6)^2 + (10-4)^2 = 52 \quad d(x_4, x_6)^2 = (5-6)^2 + (8-4)^2 = 17$$

$$d(x_7, x_6)^2 = (1-6)^2 + (2-4)^2 = 29 \quad \text{Logo } x_6 \rightarrow C_2$$

$x_7(1, 2)$

$x_7 \rightarrow C_3$

$x_8(4, 9)$:

$$d(x_1, x_8)^2 = (2-4)^2 + (10-9)^2 = 5 \quad d(x_4, x_8)^2 = (5-4)^2 + (8-9)^2 = 2$$

$$d(x_7, x_8)^2 = (1-4)^2 + (2-9)^2 = 58 \quad \text{Logo } x_8 \rightarrow C_2$$

Assim termos:

$C_1: x_1$; $C_2: x_3, x_4, x_5, x_6, x_8$; $C_3: x_2, x_7$

3

2) "Adjust centroids" \rightarrow c/ a média dos pontos atribuídos a cada centroide cluster, seguem μ_1, μ_2, μ_3 os novos centroides dos clusters

$C_1:$

só tem um ponto, logo o centroide mantém-se. (pq o ponto é o centroide)

$$\mu_1 = x_1 = (2, 10)$$

$C_2: \{x_3, x_4, x_5, x_6, x_8\}$

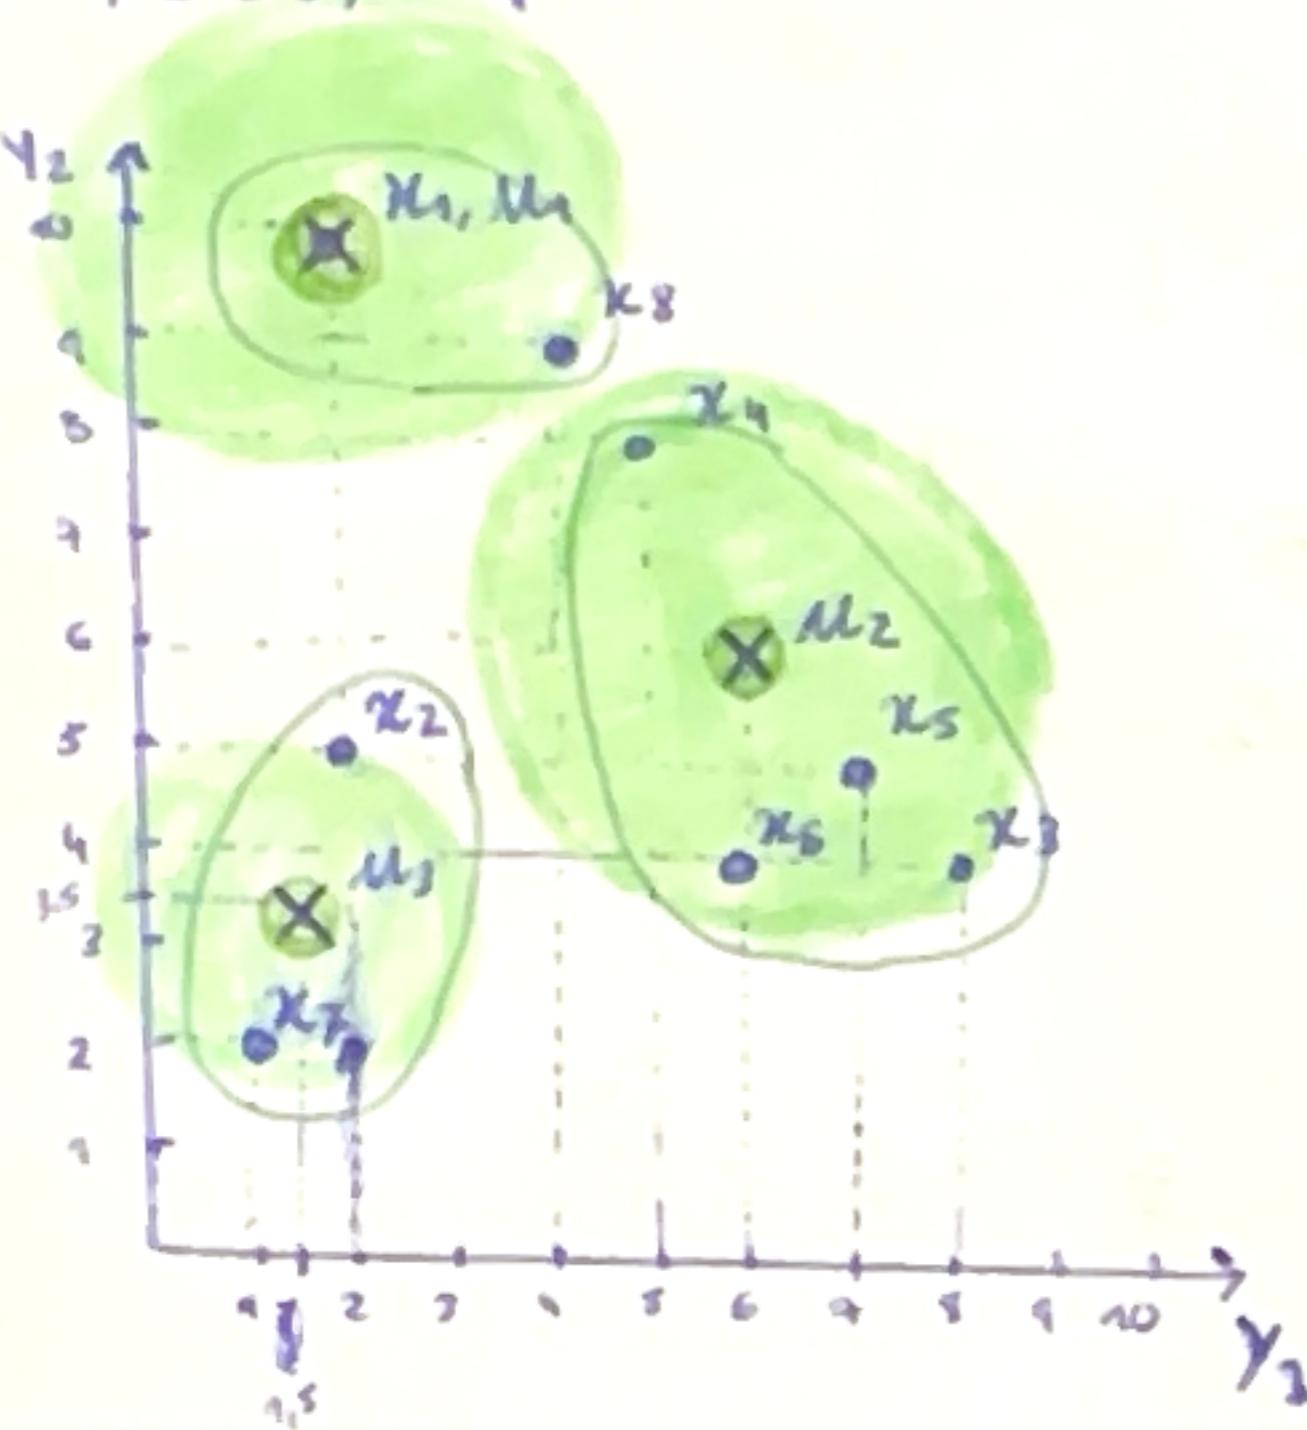
$$\mu_2 = \begin{bmatrix} \frac{8+3+7+6+4}{5} \\ \frac{4+8+5+4+9}{5} \end{bmatrix}^T = (6, 6)$$

$C_3: \{x_2, x_7\}$

$$\mu_3 = \begin{bmatrix} \frac{2+2}{2} \\ \frac{5+2}{2} \end{bmatrix}^T = (1,5; 3,5)$$

R: Os novos centroides são $\mu_1 = (2, 10); \mu_2 = (6, 6); \mu_3 = (1,5; 3,5)$ dos clusters 1, 2 e 3, respectivamente

c)



$C_1 = \{x_1, x_8\}$

$C_2 = \{x_3, x_4, x_5, x_6, x_8\}$

$C_3 = \{x_2, x_7\}$

Para os novos centroides calculados, temos de voltar a atribuir cada observação aos clusters

$x_1 = \mu_1$ logo $x_1 \rightarrow C_1$

$x_2:$

$$d(\mu_1, x_2)^2 = 25; d(\mu_2, x_2)^2 = (2-6)^2 + (5-6)^2 = 17$$

$$d(\mu_3, x_2)^2 = (2-1,5)^2 + (5-3,5)^2 = 2,5; x_2 \rightarrow C_3$$

$x_3:$

$$d(\mu_1, x_3)^2 = 72; d(\mu_2, x_3)^2 = (3-6)^2 + (4-6)^2 = 8$$

$$d(\mu_3, x_3)^2 = (8-1,5)^2 + (4-3,5)^2 = 42,5; x_3 \rightarrow C_2$$

$x_4:$

$$d(\mu_1, x_4)^2 = 13; d(\mu_2, x_4)^2 = (5-6)^2 + (8-6)^2 = 5$$

$$d(\mu_3, x_4)^2 = (5-1,5)^2 + (8-3,5)^2 = 32,5; x_4 \rightarrow C_2$$

$x_5:$

$$d(\mu_1, x_5)^2 = 50; d(\mu_2, x_5)^2 = (7-6)^2 + (5-6)^2 = 2$$

$$d(\mu_3, x_5)^2 = (7-1,5)^2 + (5-3,5)^2 = 32,5; x_5 \rightarrow C_2$$

$x_6:$

$$d(\mu_1, x_6)^2 = 52; d(\mu_2, x_6)^2 = (6-6)^2 + (4-6)^2 = 2$$

$$d(\mu_3, x_6)^2 = (6-1,5)^2 + (4-3,5)^2 = 20,5 x_6 \rightarrow C_2$$

$x_7:$

$$d(\mu_1, x_7)^2 = 65; d(\mu_2, x_7)^2 = (1-6)^2 + (2-6)^2 = 41$$

$$d(\mu_3, x_7)^2 = (1-1,5)^2 + (2-3,5)^2 = 2,5; x_7 \rightarrow C_3$$

$x_8:$

$$d(\mu_1, x_8)^2 = 5; d(\mu_2, x_8)^2 = (4-6)^2 + (9-6)^2 = 13$$

$$d(\mu_3, x_8)^2 = (4-1,5)^2 + (9-3,5)^2 = 36,5 x_8 \rightarrow C_1$$

OS clusters são círculos, centrados nos centroides e raio de, respectivamente r_1, r_2, r_3 :

$$\therefore \sqrt{5}; \sqrt{8}; \sqrt{2,5}$$

Representados por (não alinhado)

d) O algoritmo k-means está muito dependente da inicialização dos centrídeos, afetando diretamente a convergência e a performance do modelo

- Tempo de convergência (tempo até terminar o algoritmo e não ~~seja~~ necessárias ^{serem} mais épocas pois os centrídeos não alteraram)

Uma inicialização mais próxima da solução final ótima requer menos iterações / épocas para os centrídeos estabilizarem as suas posições.

Pelo contrário, uma inicialização pobre pode exigir um número muito maior de épocas para que os centrídeos se desloquem através do espaço de dados até encontrarem as suas posições finais, tornando o processo computacionalmente mais lento

- Performance (desempenho / qualidade do algoritmo, ou seja, se chegou ou não à distribuição das observações por clusters mais acertada)

Há algumas circunstâncias em que, devido à inicialização dos centrídeos, a performance fica comprometida:

→ Se forem inicializados muito próximos uns dos outros, o algoritmo pode ter dificuldade a separar clusters que são naturalmente distintos.

→ Se forem ^{pode} inicializados equidistantemente des ~~as~~ K clusters, também a performance ~~fica~~ ficar comprometida



→ Uma inicialização de ^{um} centrídeo que nenhum ponto de dados lhe seja o mais próximo, pode levar à formação de cluster vazios, pois o centrídeo fica "preso" e incapaz de se atualizar (só que só faz média ci ele mesmo)

Para além disso, como o k-means é um algoritmo greedy, há certas inicializações de centrídeos que podem fazer o modelo convergir para mínimos locais, não atingindo a solução ótima e separação natural dos dados.

Part B - PCA

a) 1) centrar os dados

$$\bar{x} = \frac{1}{3} \left[\begin{bmatrix} 5 \\ 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 5 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 5 \end{bmatrix} \right] = \begin{bmatrix} 6/3 \\ 5/3 \\ 0/3 \end{bmatrix} = \begin{bmatrix} 2 \\ 5/3 \\ 0 \end{bmatrix} \rightarrow \begin{array}{l} y_1 \\ y_2 \\ y_3 \end{array}$$

$$x'_i = x_i - \bar{x} \quad x'_1 = \begin{bmatrix} 5 \\ 0 \\ 1 \end{bmatrix} - \begin{bmatrix} 2 \\ 5/3 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ -5/3 \\ 1 \end{bmatrix} \quad x'_2 = \begin{bmatrix} 0 \\ 5 \\ 0 \end{bmatrix} - \begin{bmatrix} 2 \\ 5/3 \\ 0 \end{bmatrix} = \begin{bmatrix} -2 \\ 10/3 \\ 0 \end{bmatrix} \quad x'_3 = \begin{bmatrix} 1 \\ 0 \\ 5 \end{bmatrix} - \begin{bmatrix} 2 \\ 5/3 \\ 0 \end{bmatrix} = \begin{bmatrix} -1 \\ -5/3 \\ 5 \end{bmatrix}$$

Matriz das covariâncias:

$$\begin{bmatrix} \text{var}(y_1) & \text{cov}(y_1, y_2) & \text{cov}(y_1, y_3) \\ \text{cov}(y_2, y_1) & \text{var}(y_2) & \text{cov}(y_2, y_3) \\ \text{cov}(y_3, y_1) & \text{cov}(y_3, y_2) & \text{var}(y_3) \end{bmatrix} \quad \text{var}(y_1) = \text{cov}(y_1, y_1) = \frac{(5-2)^2 + (0-2)^2 + (1-2)^2}{3-1} = \frac{14}{2} = 7$$

$$\text{var}(y_2) = \text{cov}(y_2, y_2) = \frac{(0-5/3)^2 + (5-5/3)^2 + (0-5/3)^2}{3-1} = \frac{50/3}{2} = 8,1(3)$$

$$\text{var}(y_3) = \text{cov}(y_3, y_3) = \frac{(1-0)^2 + (0)^2 + (-1-0)^2}{3-1} = 1$$

$$\text{cov}(y_1, y_2) = \text{cov}(y_2, y_1) = \frac{(5-2)(-5/3) + (-2)(5-5/3) + (-5/3)(1-2)}{3-1} = \frac{-10}{2} = -5$$

$$\text{cov}(y_1, y_3) = \text{cov}(y_3, y_1) = \frac{(5-2)(1) + (-2)(0) + (1-2)(-1)}{3-1} = \frac{4}{2} = 2$$

$$\text{cov}(y_2, y_3) = \text{cov}(y_3, y_2) = \frac{(-5/3)(1) + (5-5/3)(0) + (-5/3)(-1)}{3-1} = \frac{0}{2} = 0$$

Assim, temos a matriz das covariâncias:

$$\Sigma = \begin{bmatrix} 7 & -5 & 2 \\ -5 & 8,1(3) & 0 \\ 2 & 0 & 1 \end{bmatrix}$$

b) calcular valores e vetores próprios de Σ

Valores Próprios

$$\det(\Sigma - \lambda I) = 0 \Leftrightarrow \begin{vmatrix} 7-\lambda & -5 & 2 \\ -5 & 25/3-\lambda & 0 \\ 2 & 0 & 1-\lambda \end{vmatrix} = 0 \Leftrightarrow 2 \begin{vmatrix} -5 & 2 \\ 25/3-\lambda & 0 \end{vmatrix} - 0 \begin{vmatrix} 7-\lambda & 2 \\ -5 & 0 \end{vmatrix} + (1-\lambda) \begin{vmatrix} 7-\lambda & -5 \\ -5 & 25/3-\lambda \end{vmatrix} = 0 \Leftrightarrow$$

$$\Leftrightarrow 2 \left(-\left(\frac{50}{3} - 2\lambda \right) \right) + (1-\lambda) \left((7-\lambda)\left(\frac{25}{3} - \lambda \right) - 25 \right) = 0 \Leftrightarrow -\frac{100}{3} + 4\lambda + \frac{100}{3} - \frac{146}{3}\lambda + \frac{49}{3}\lambda^2 - \lambda^3 = 0 \Leftrightarrow$$

$$\Leftrightarrow -\lambda^3 + \frac{49}{3}\lambda^2 - \frac{134}{3}\lambda = 0 \Leftrightarrow -\lambda \left(\lambda^2 - \frac{49}{3}\lambda + \frac{134}{3} \right) = 0 \Leftrightarrow \lambda_3 = 0 \vee \lambda^2 - \frac{49}{3}\lambda + \frac{134}{3} = 0 \Leftrightarrow$$

$$\Leftrightarrow \lambda_3 = 0 \vee \lambda_1 = 3,47 \vee \lambda_2 = 12,86$$

Quanto maior o valor próprio, maior a variação ~~explicada~~ dos dados, explicada pelo vetor próprio correspondente.

Como queremos o plano (2 dim) de projeção, escolhemos os 2 maiores valores próprios $\lambda_1 \wedge \lambda_2$ escolhidos, vamos calcular os correspondentes vetores próprios, $u_1 \wedge u_2$. Para $\lambda_1 = 3,47$, vetor próprio u_1

$$(\Sigma - \lambda_1 I)u_1 = 0 \Leftrightarrow \begin{bmatrix} 7-3,47 & -5 & 2 \\ -5 & 25/3-3,47 & 0 \\ 2 & 0 & 1-3,47 \end{bmatrix} \begin{bmatrix} u_{11} \\ u_{12} \\ u_{13} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \Leftrightarrow$$

$$\begin{cases} 3,53u_{11} - 5u_{12} + 2u_{13} = 0 \\ -5u_{11} + 5,83u_{12} = 0 \\ 2u_{11} - 2,47u_{13} = 0 \end{cases} \Leftrightarrow \begin{cases} - \\ u_{12} = 1,028u_{11} \\ u_{13} = 0,8097u_{11} \end{cases} \quad \text{se } u_{11} = 1; u_{12} = 1,028; u_{13} = 0,8097$$

$$u_1 = (1, 1, 028, 0, 8097) \quad \|u_1\| = \sqrt{1+1,0572+0,6556} = 1,647$$

$$u_{1,\text{norm}} = \frac{u_1}{\|u_1\|} \approx (0,607, 0,624, 0,492)$$

Para $\lambda_2 = 12,86$, vetor próprio U_2

$$(\Sigma - \lambda_2 I) U_2 = 0 \Leftrightarrow \begin{bmatrix} 7-12,86 & -5 & 2 \\ -5 & 23,86-12,86 & 0 \\ 2 & 0 & 1-12,86 \end{bmatrix} \begin{bmatrix} U_{21} \\ U_{22} \\ U_{23} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \Leftrightarrow \begin{cases} -5,86U_{21} - 5U_{22} + 2U_{23} = 0 \\ -5U_{21} - 4,527U_{22} = 0 (=) \\ 2U_{21} - 11,86U_{23} = 0 \end{cases}$$

$\Leftrightarrow \begin{cases} U_{22} = 1,105U_{21} - 1,105U_{21} \\ U_{23} = 0,1686U_{21} \end{cases}$ se $U_{21} = 1$; $U_{22} = -1,105$; $U_{23} = 0,1686$
 $U_2 = (1; -1,105; 0,1686)$ $\|U_2\| = \sqrt{1+1,22+0,0284} \approx 1,5$

$$U_{2,\text{norm}} = \frac{U_2}{\|U_2\|} = (0,667; -0,737; 0,1124)$$

U_1 e U_2 são vetores linearmente independentes (perpendiculares entre si) $U_1 \cdot U_2 = 0$ e juntos formam um plano, ou seja, constituem a base orthonormal ideal para projetar, em que qualquer combinação linear $aU_1 + bU_2$ ($a, b \in \mathbb{R}^2$) dá um ponto desse plano.

$\text{Span}\{(0,607; 0,624; 0,492), (0,667; -0,737; 0,1124)\} \rightarrow$ Plano ótimo 2D

c)

$$x^1 = U^T x \quad , \quad U = \begin{bmatrix} 1 & 1 & 1 \\ U_1 & U_2 & U_3 \\ 1 & 1 & 1 \end{bmatrix} \quad , \text{ seja } U_3(a, b, c) \text{ (irrelevante)}$$

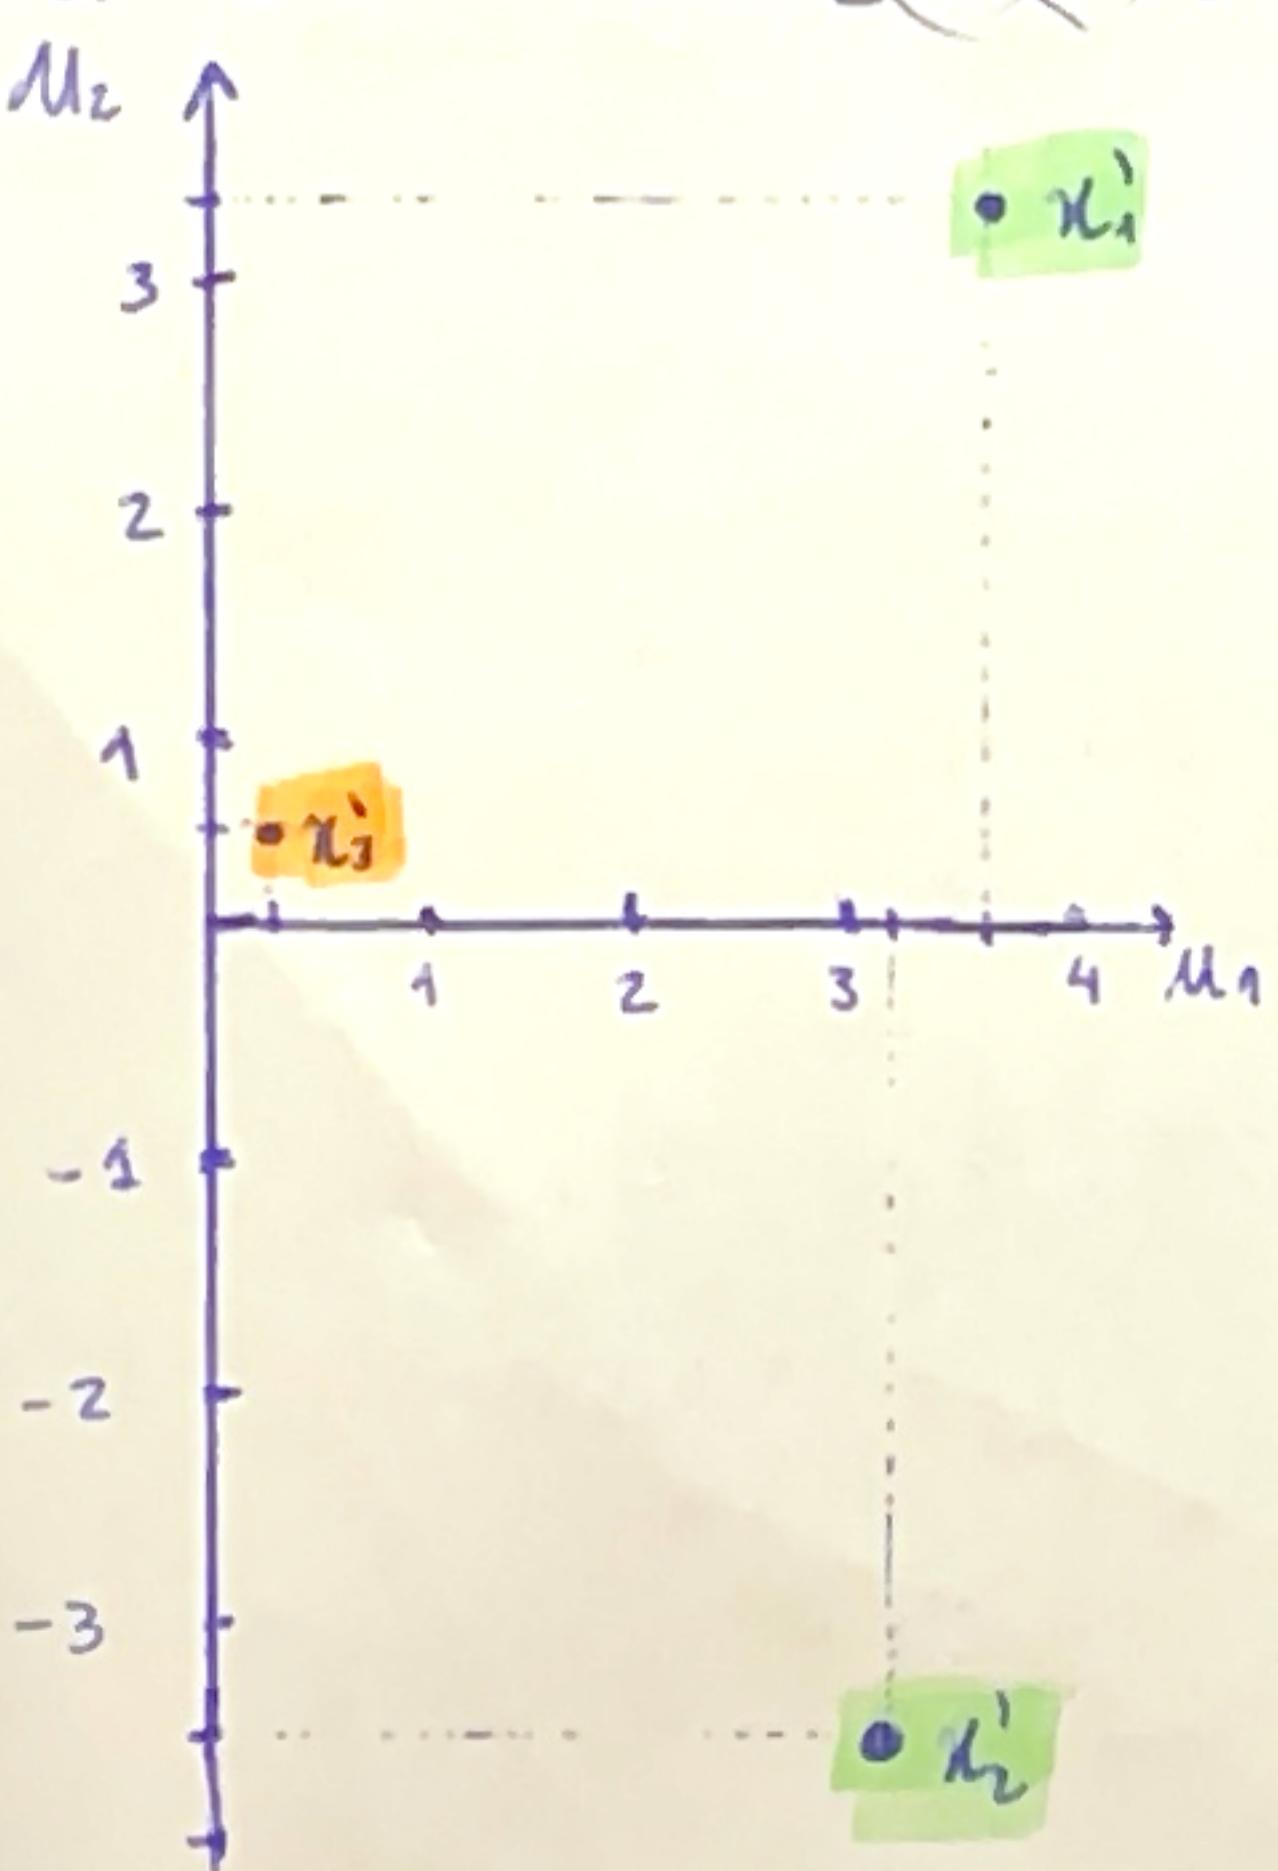
$$= \begin{bmatrix} 0,607 & 0,667 & a \\ 0,627 & -0,737 & b \\ 0,492 & 0,1124 & c \end{bmatrix} \quad U^T = \begin{bmatrix} 0,607 & 0,627 & 0,492 \\ 0,667 & -0,737 & 0,1124 \\ a & b & c \end{bmatrix}$$

$$x_1' = U^T \begin{bmatrix} 5 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 5 \times 0,607 + 0,492 \\ 5 \times 0,667 + 0,1124 \\ 5a + c \end{bmatrix} = \begin{bmatrix} 3,527 \\ 3,4474 \\ 5a+c \end{bmatrix} \rightarrow \begin{bmatrix} 3,527 \\ 3,447 \end{bmatrix} (3,527; 3,447) \rightarrow x_1'$$

$$x_2' = U^T \begin{bmatrix} 0 \\ 5 \\ 0 \end{bmatrix} = \begin{bmatrix} 5 \times 0,627 \\ 5 \times (-0,737) \\ -5b \end{bmatrix} = \begin{bmatrix} 3,135 \\ -3,685 \\ -5b \end{bmatrix} \xrightarrow{\text{irrelativo a } \lambda_3, \text{ descartado}} \begin{bmatrix} 3,135 \\ -3,685 \end{bmatrix} (3,135; -3,685) \rightarrow x_2'$$

$$x_3' = U^T \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 0,607 - 0,492 \\ 0,667 - 0,1124 \\ a - c \end{bmatrix} = \begin{bmatrix} 0,115 \\ 0,5546 \\ a-c \end{bmatrix} \rightarrow \begin{bmatrix} 0,115 \\ 0,5546 \end{bmatrix} (0,115; 0,5546) \rightarrow x_3'$$

a primeira coordenada é relativa a U_1 e a segunda a U_2



Pos (+) Podemos analisar os pontos positivos no plano de projeção, no entanto apenas 3 pontos é limitado para garantir um padrão discriminatório.

Neg (-) Podemos interpretar que os pontos positivos estão mais longe da origem enquanto o ponto de classe negativa x_3' está mais perto da origem.